

SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I
INFORMACIJSKIH TEHNOLOGIJA OSIJEK

Diplomski studij

KLASIFICIRANJE VRSTE CVIJETA IRISA POMOĆU
NEURONSKIH MREŽA

Meko računarstvo
Laboratorijska vježba 4

Andrej Bošnjak
DRB

Osijek, 2023.

SADRŽAJ

1. UVOD	1
2. OPIS PROBLEMA I RJEŠENJA.....	2
2.1. Neuronska mreža (NN).....	2
2.2. Parametri	4
3. REZULTATI	4
3.1. Najbolji rezultati	4
3.2. Prosječni rezultati	11
3.3. Najlošiji rezultati.....	17
4. Zaključak	23

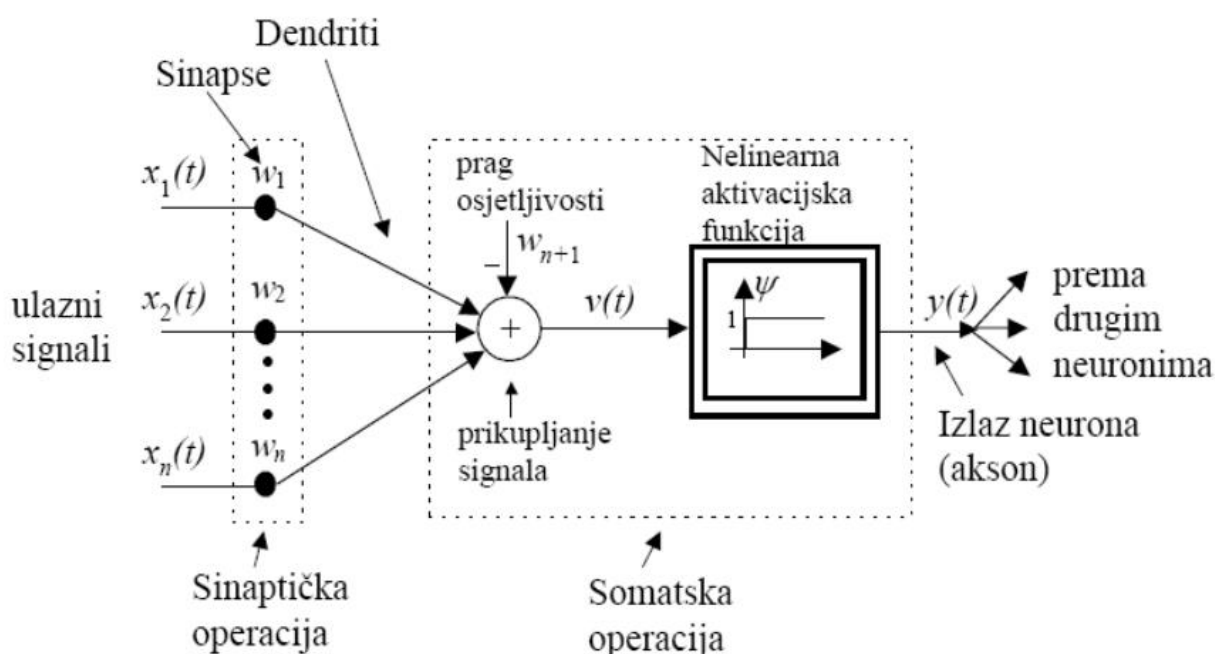
1. UVOD

Na petoj laboratorijskoj vježbi se klasificira vrste cvijeća irisa pomoću neuronskih mreža. Također se i ispituje na temelju ulaznih i izlaznih podataka i računa preciznost pomoću matrice konfuzije. Cilj je uočiti kako određeni parametri mreže utječu na dobivene rezultate.

2. OPIS PROBLEMA I RJEŠENJA

2.1. Neuronska mreža (NN)


Neuronske mreže su sustavi za procesuiranje informacija koji su inspirirani biološkim živčanim sustavom kao što je mozak. Sastoji se od uvjetno rečeno velikog broja međusobno povezanih procesnih elemenata tzv. neurona. Svaki neuron je u biti sumirajući element povezan sa aktivacijskom funkcijom. Biološki neuroni primaju elektrokemijske pobude preko dendrita, a ako je težinska suma svih ulaza na dendritima veća od praga, neuron okida i šalje impuls na aksion preko kojeg je spojen s ulazima ostalih neurona. Prvi model neurona koji je bio osmišljen još 1943. od strane McCullocha i Pittsa se zvao „perceptron“ i njegova jedina razlika od modernijih modela neurona je bila ta što je kao prijenosnu funkciju koristio diskontinuiranu step funkciju. Dok su se kasnije puno logičnije počele koristiti kontinuirane funkcije, bile one linearne ili sigmoidalne (logsig, tansig). Jer u slučaju kontinuirane funkcije imamo mogućnosti puno preciznije aproksimacije modela problema. Ali je najveća revolucija započela uvođenjem višeslojnih mreža i njihovih algoritama za učenje. Shematski prikaz perceptrona je vidljiv na slici 1.



Slika 2.1 Shematski prikaz perceptrona

Kao što se vidi na slici 1, svaki neuron prikuplja signale od prethodnog sloja (pomnožene sa težinama), te uz dodatak praga osjetljivosti dolazi do prijenosne funkcije odnosno nelinearne aktivacijske funkcije. Izlaz iz te funkcije potom odlazi do svakog neurona u idućem sloju gdje se proces ponavlja. Neuroni se najčešće dijele na statičke i dinamičke, gdje statički neuroni ovise

isključivo o trenutnim vrijednostima signala i težina, dok kod dinamičkih postoje određene povratne veze i promjenjive aktivacijske funkcije. Kao što je ranije rečeno aktivacijske funkcije najčešće su sigmoide kao što vidimo na slijedećim slikama.



Slika 2.2 Aktivacijske funkcije

Da bi se neuronska mreža definirala, pored osnovnih parametara koji opisuju oblik i tip mreže, odnosno arhitekturu, potrebno je odrediti i algoritam učenja. Proces učenja je u biti proces optimizacije pomoću algoritma gdje se pronalaze težine između neurona koje najbolje opisuju rješenje odnosno aproksimaciju problema. Proces učenja najčešće uključuje slijedeće korake:

- Dovođenje na ulaz neuronske mreže niz slučajeva (uzoraka) koje želimo naučiti raspoznavati.
- Odrediti pogrešku između dobivenog izlaza i željenog izlaza.
- Promijeniti težine da bi se izlaz bolje aproksimirao.

Iako broj neurona nije ograničen do sada se je u praktičnim primjenama koristilo do najviše par stotina neurona i to u jako kompleksnim primjenama. Jer uvođenjem dodatnih neurona (i slojeva) višestruko povećava problem učenja, a može se dogoditi da u slučaju pretjeranog broja neurona (za pojedini problem) može unijeti smetnje u izlaz neuronske mreže zbog neskladnog rada. Imamo 3 osnovna tipa učenja neuronskih mreža:

- Nadzirano učenje – učenje na temelju poznatih uzoraka i rezultata

- Učenje pojačavanjem – uključuje povratnu vezu iz okoline
- Nenadzirano učenje – učenje iz pravilnosti ulaznih podataka.

Najčešće se koristi nadzirano učenje, a najčešće korišteni algoritam učenja je sa povratnom propagacijom pogreške (eng. backpropagation).

Neuronske mreže zbog svoje sposobnosti učenja i aproksimacije se najčešće koristi za slijedeće primjene:

- Raspoznavanje znakova teksta (i analiza slike),
- Prepoznavanje govora,
- Adaptivno uklanjanje šuma,
- Predviđanje cijena dionica(financije),
- Medicinska dijagnostika.

2.2. Parametri

Parametri neuronske mreže koji se mijenjaju:

- Broj neurona po skrivenom sloju: 5, 10, 30.
- Broj skrivenih slojeva: 1, 2, 3.
- Aktivacijska funkcija skrivenog sloja: ‘identity’, ‘logistic’, ‘tanh’, ‘relu’.
- Algoritam učenja: ‘lbfgs’, ‘sgd’, ‘adam’.

3. REZULTATI

Svi rezultati su prikazani u idućim podnaslovima. Zbog velike količine kombinacija parametara, od rezultata je uzeto 10 najboljih, 10 prosječnih i 10 najgorih rezultata gledanih po preciznosti.

3.1. Najbolji rezultati

10nNeurons_1nLayers_tanh_sgd: 0.9733333333333334

10nNeurons_1nLayers_tanh_adam: 0.9733333333333334

15nNeurons_1nLayers_relu_sgd: 0.9733333333333334

15nNeurons_1nLayers_logistic_adam: 0.9733333333333334

15nNeurons_2nLayers_relu_lbfgs: 0.9733333333333334

10nNeurons_1nLayers_identity_adam: 0.9866666666666667


15nNeurons_1nLayers_relu_adam: 0.9866666666666667

5nNeurons_1nLayers_logistic_adam: 0.9866666666666667


10nNeurons_2nLayers_relu_lbfgs: 0.9866666666666667


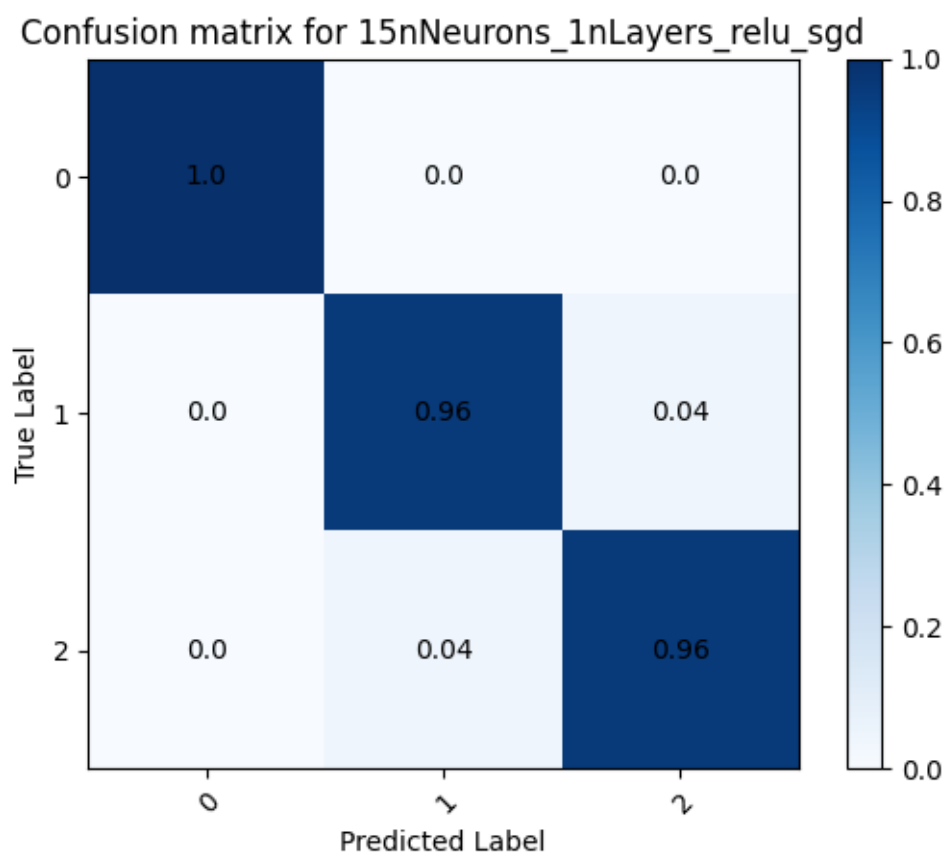
10nNeurons_1nLayers_logistic_adam: 0.9866666666666667

Confusion matrix for 10nNeurons_1nLayers_tanh_sgd




Confusion matrix for 10nNeurons_1nLayers_tanh_adam







Confusion matrix for 15nNeurons_2nLayers_relu_lbfgs




Confusion matrix for 10nNeurons_1nLayers_identity_adam




Confusion matrix for 15nNeurons_1nLayers_relu_adam




Confusion matrix for 5nNeurons_1nLayers_logistic_adam



Confusion matrix for 10nNeurons_2nLayers_relu_lbfgs



Confusion matrix for 10nNeurons_1nLayers_logistic_adam



3.2. Prosječni rezultati

15nNeurons_2nLayers_relu_adam: 0.9466666666666667

10nNeurons_2nLayers_identity_lbfgs: 0.9466666666666667

15nNeurons_3nLayers_identity_lbfgs: 0.9466666666666667

5nNeurons_3nLayers_tanh_adam: 0.9466666666666667

5nNeurons_3nLayers_relu_lbfgs: 0.9466666666666667

5nNeurons_2nLayers_tanh_sgd: 0.9466666666666667


5nNeurons_2nLayers_tanh_adam: 0.9466666666666667

5nNeurons_2nLayers_relu_lbfgs: 0.9466666666666667


5nNeurons_2nLayers_relu_sgd: 0.9466666666666667

10nNeurons_3nLayers_relu_sgd: 0.9466666666666667


Confusion matrix for 10nNeurons_2nLayers_identity_lbfgs




Confusion matrix for 15nNeurons_3nLayers_identity_lbfgs







Confusion matrix for 5nNeurons_3nLayers_tanh_adam


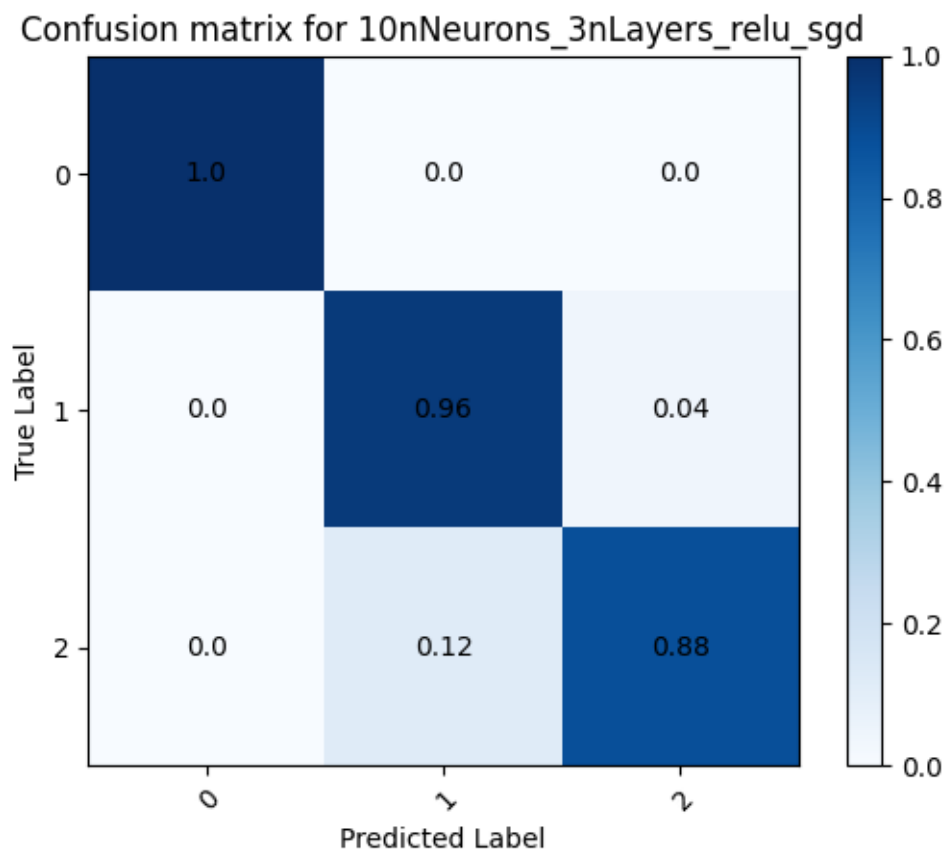


Confusion matrix for 5nNeurons_3nLayers_relu_lbfgs









3.3. Najboljši rezultati

15nNeurons_3nLayers_relu_sgd: 0.3333333333333333

5nNeurons_3nLayers_tanh_sgd: 0.3333333333333333

15nNeurons_2nLayers_logistic_sgd: 0.3333333333333333

5nNeurons_2nLayers_logistic_sgd: 0.3333333333333333

10nNeurons_2nLayers_logistic_sgd: 0.3333333333333333

5nNeurons_2nLayers_identity_sgd: 0.3333333333333333


5nNeurons_1nLayers_relu_sgd: 0.3333333333333333

15nNeurons_3nLayers_logistic_sgd: 0.3333333333333333


5nNeurons_3nLayers_logistic_sgd: 0.3333333333333333

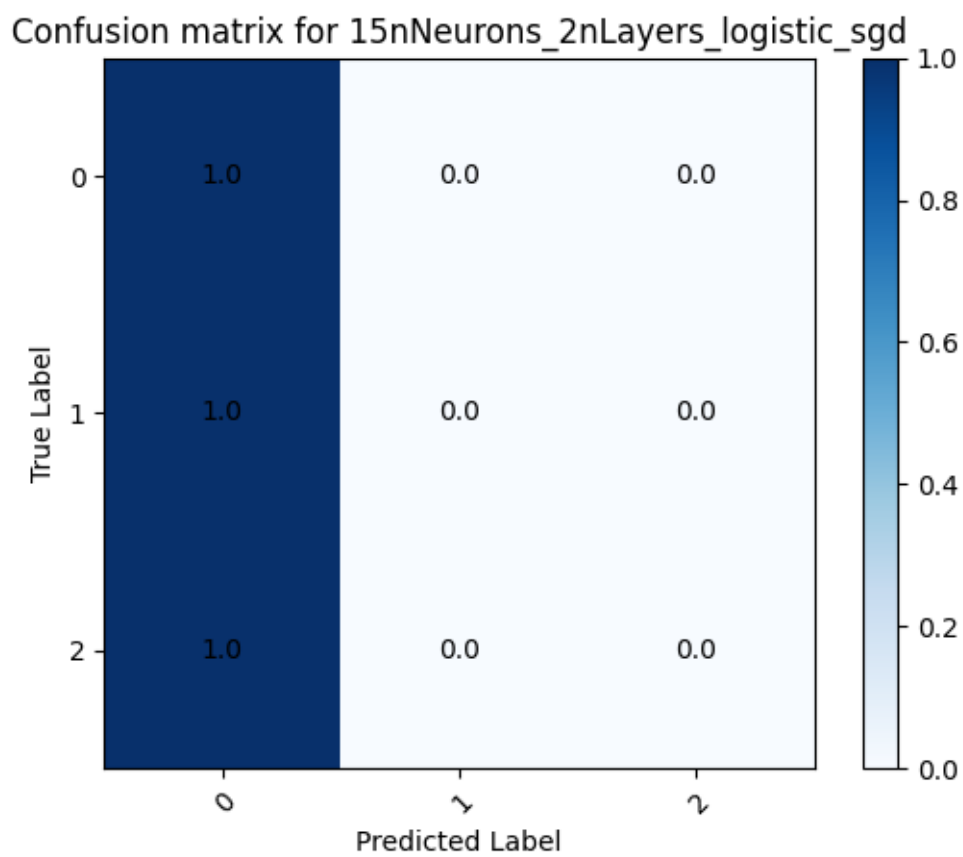
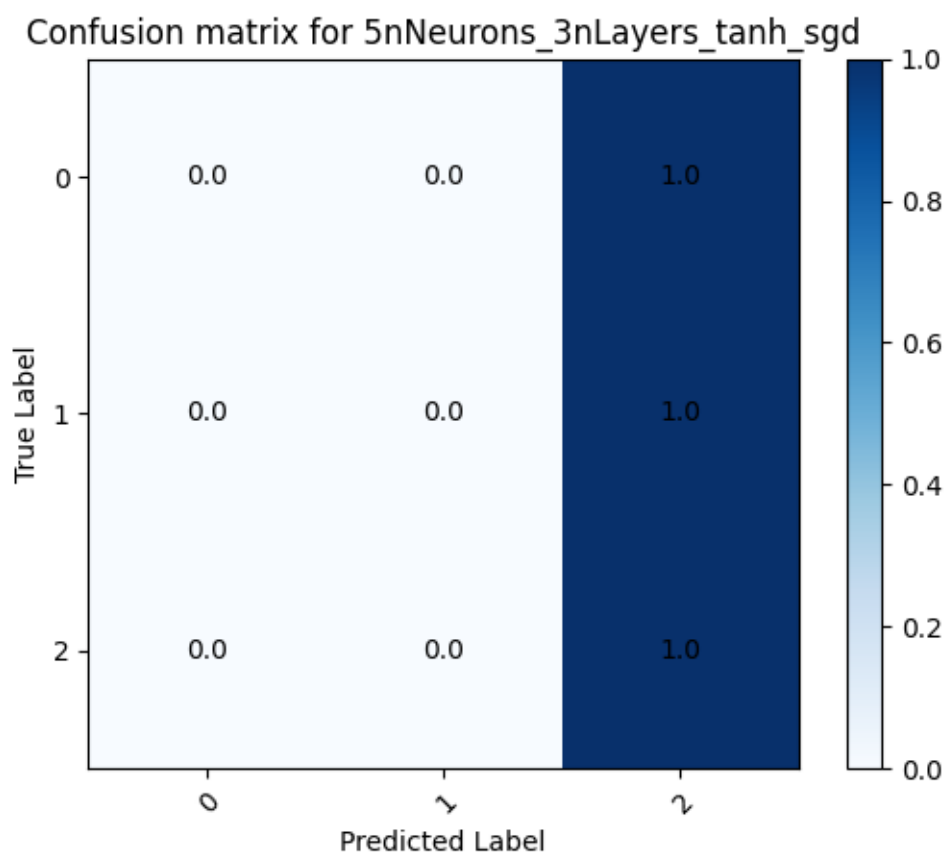
10nNeurons_3nLayers_logistic_sgd: 0.3333333333333333

Confusion matrix for 10nNeurons_3nLayers_logistic_sgd




Confusion matrix for 15nNeurons_3nLayers_relu_sgd







Confusion matrix for 5nNeurons_2nLayers_logistic_sgd



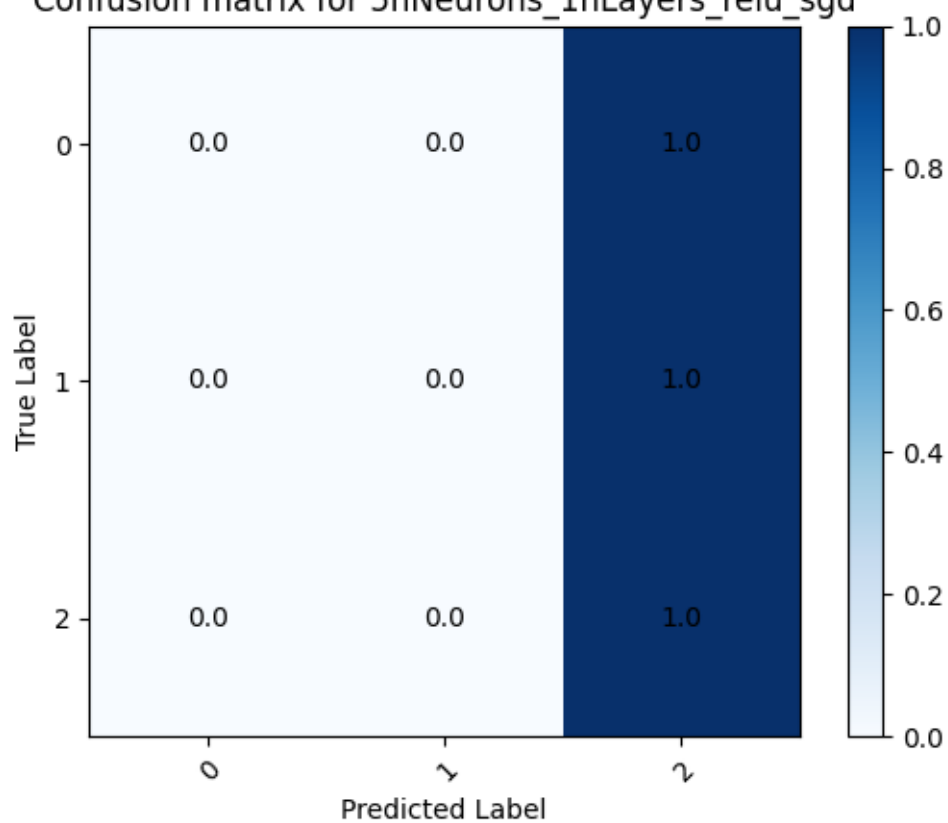
Confusion matrix for 10nNeurons_2nLayers_logistic_sgd




Confusion matrix for 5nNeurons_2nLayers_identity_sgd




Confusion matrix for 5nNeurons_1nLayers_relu_sgd



Confusion matrix for 15nNeurons_3nLayers_logistic_sgd



Confusion matrix for 5nNeurons_3nLayers_logistic_sgd



4. Zaključak

Nakon izvršenih kombinacija parametara za navedenu neuronsku mrežu, vidljivo je da promjenom bilo kojih parametara utječemo na rezultat.

Vidljivo je da su najbolji rezultati uz kombinaciju sa 10 ili 15 neurona i jednim skrivenim slojem.

Općenito više skrivenih slojeva daju malo lošije rezultate.

Najlošiji rezultati su sa algoritmom za učenje „sgd“ i 2 ili više skrivenih slojeva. Također i aktivacijska funkcija „logistic“ je česta među najlošijim rezultatima.

Puno srednjih rezultata sadržavaju 2 i 3 skrivenih slojeva i mali broj neurona po sloju, što ukazuje na to da je potrebno pronaći optimalni ukupni broj neurona.